


DETECCIÓN DE FRAUDES EN OFERTAS DE EMPLEO

Telmo Esparza, Aitor Otegi, Aitzol Salaberria

01

Descripción Dataset





Origen de los Datos

"Real / Fake Job Posting Prediction"
De Shivam Bansal

Tipos de Variables

<i>Tipo</i>	<i>Variable</i>
Identificador	job_id
Texto Largo	company_profile, description, requirements, benefits
Texto	title, location, department, salary_range, employment_type, required_experience, required_education, industry, function
Binario	telecommuting, has_company_logo, has_questions


Cantidad de Nulos

<i>Variable</i>	<i>Nulos</i>
department	65%
salary_range	84%
company_profile	19%
requirements	15%
benefits	40%

employment_type	19%
required_experience	39%
required_education	45%
industry	27%
function	36%



Variable a predecir

fraudulent = 0	4.8%
fraudulent = 1	95.2%



Relación entre Variables

(Después de Preprocesar)



02

Métricas de Rendimiento






Elección de la Métrica

Principal: Área bajo la curva
Precision-Recall.


Secundarias: Precision, Recall,
F1-Score

Metodología de Validación



03


Preparación de Datos



Limpieza de Formato



Limpiar
Espacios



Minusculizar



Quitar
Símbolos



Quitar
tildes

Imputación de Nulls

1.1

*Imputación
Constante*

1.2

*Rellenado 0-1 de
Salary Range*

1.3

*Rellenado
discreto de
Salary Range*

1.4

*Imputación por
Moda*

1.5

*Imputación
por Moda por
Grupos*

Codificación de Variables

2.1

Contar Palabras

2.2

Contar Letras

2.3

Binary Encoder

2.4

Target Encoder

2.5

Ordinal Encoder

2.6

Count Vectorizer



Selección de Variables

3.1

*Probar
combinaciones
de variables de
texto largo*

3.2

*Elegir K
variables con
más correlación*



04

Técnicas para evitar desbalanceo

Muestreo de Datos

Nº de ejemplos: 12.873

1.1

CNN

1.2

Tomek Links

1.3


OSS

1.4

NCL

1.5

*Random Over
Sampler*




Ajuste del Umbral

Solución: Probar todos los posibles umbrales de la curva Precision-Recall y quedarnos con el mejor.

05

Modelos






KNN


Arbol de decisión

06

Experimentos



Modelo base



Imputación de Nulls

salary_range

<i>Experimento</i>	<i>Resultado</i>
Rellenado con Constante	59%
Rellenado de salary_range 1-0	80%
Rellenado de salary_range discreto	82%

Imputación de Nulls


Resto de Variables

<i>Experimento</i>	<i>Resultado</i>
Imputación por moda	82%
Imputación por moda por grupos	78%
Rellenado de salary_range discreto	82%

Codificación de Variables


<i>Experimento</i>	<i>Resultado</i>
Contar Palabras	65%
Contar Letras	61%
Binary Encoder	66%
Ordinal Encoder	22%
Count Vectorizer	78%

Selección de Variables de texto largo




Mejor combinación: Todos menos requirements


Selección de Variables por correlación (cálculo de K)



Selección de Instancias por defecto



Selección de Instancias con los mejores n vecinos




Mejor: Tomek Links

Ajuste de Hiperpárametros de KNN (GridSearchCV)

<i>Hiperparámetro</i>	<i>Opciones</i>	<i>Mejor Opción</i>
Número de vecinos	[1, 3, 5, 7]	7
Pesos	"uniform" y "distance"	"distance"
p	[1, 1.5, 2, 3]	1.5

Ajuste de Hiperpárametros de KNN (GridSearchCV)




Mejor umbral: 0.738
Fscore en validación: 82%

Ajuste de Hiperpárametros de Árboles de Decisión (GridSearchCV)

<i>Hiperparámetro</i>	<i>Opciones</i>	<i>Mejor Opción</i>
Criterio	"Giny", "Entropy"	"Giny"
min_samples_split	[0.01, 0.05, 0.1]	0.01
min_samples_leaf	[0.01, 0.05, 0.1]	0.01
Profundidad Máxima	[10, 50, 100]	50
Alfa	[0, 0.01, 0.1]	0

Ajuste de Hiperpámetros De Árboles de Decisión (GridSearchCV)



Mejor umbral: 0.363
Fscore en validación: 73.3%

07

Modelo definitivo



Modelo Definitivo



*Limpiar
Espacios*




Minusculizar




*Quitar
Símbolos*




*Quitar
tildes*



Modelo Definitivo



Modelo Definitivo



Modelo Definitivo

Resultado

81.01%

Modelo Definitivo

Matriz de Confusión

		Predicción	
		Fraude	No Fraude
Real	Fraude	64	23
	No Fraude	7	1694

08

Interpretabilidad




Grafico de barras




Grafico de puntos






Grafico de cascada



09

Conclusiones





FIN